Contents

Contents 1

1 Methoden 2

1 Methoden

Step 1 – Vollständige mathematische Struktur

Für jedes Gen $|g_i\rangle$ bzw. Sample $|s_j\rangle$ als initiales Repräsentant wird folgende Prozedur durchgeführt.

Das standardisierte Restsignal $M^{\mathcal{S}}_{k-1}$

Zu Beginn jeder Detektionsiteration k liegt das aktuelle Restsignal $M_{k-1} \in \mathbb{R}^{m\times n}$ vor (für $k = 1$ ist das die Eingabematrix M_0). Daraus wird das *standardisierte Signal* $M^{\mathcal{S}}_{k-1}$ berechnet, das als Grundlage für die initialen Gewichte dient.

Motivation. In einem hochdimensionalen Raum können Gene (oder Samples), die in allen Dimensionen ähnlich stark exprimiert sind, leicht fälschlicherweise als Signaturkandidaten erscheinen – sie haben eine hohe ℓ^2-Norm, obwohl ihr Signal gleichmäßig über alle Dimensionen verteilt ist und damit typisch für Rauschen ist. Das Ziel der Standardisierung ist es, alle Gen-Vektoren *und* alle Sample-Vektoren gleichzeitig auf Einheitslänge (bezüglich der un-zentrierten Varianz) zu bringen. Dadurch erhalten Gene bzw. Samples, deren Signal auf wenige Dimensionen konzentriert ist (pures Signal), einen höheren relativen Standardisierungskoeffizienten als solche mit gleichförmig verteiltem Signal (Rauschen).

Konstruktion (Konvergenzschleife mit Index ℓ). Starte mit $M_{k-1,1} \coloneqq M_{k-1}$. In jeder Iteration ℓ:

() Berechne die un-zentrierten empirischen Varianzen aller Sample-Spalten:

$$\langle e^s_j \mid v^s_\ell \rangle \;\coloneqq\; \frac{1}{m}\sum_{i=1}^{m}\langle e^g_i \mid s_{j,\ell}\rangle^2 \;=\; \frac{1}{m}\sum_{i=1}^{m} M_{k-1,\ell}(i,j)^2. \tag{1.1}$$

() Berechne analog die un-zentrierten Varianzen aller Gen-Zeilen:

$$\langle e^g_i \mid v^g_\ell \rangle \;\coloneqq\; \frac{1}{n}\sum_{j=1}^{n}\langle e^s_j \mid g_{i,\ell}\rangle^2 \;=\; \frac{1}{n}\sum_{j=1}^{n} M_{k-1,\ell}(i,j)^2. \tag{1.2}$$

() Aktualisiere komponentenweise durch Division durch die Quadratwurzeln des äußeren Produkts $|v^g_\ell\rangle \otimes |v^s_\ell\rangle$:

$$M_{k-1,\ell+1}(i,j) \;\coloneqq\; \frac{M_{k-1,\ell}(i,j)}{\sqrt{\langle e^g_i \mid v^g_\ell\rangle \cdot \langle e^s_j \mid v^s_\ell\rangle}}\,. \tag{1.3}$$

Iteriere bis alle un-zentrierten Varianzen aller Gene und Samples innerhalb eines ϵ gleich 1 sind (Konvergenziteration $\hat{\ell}$). Das Ergebnis ist

$$M^{\mathcal{S}}_{k-1} \;\coloneqq\; M_{k-1,\hat{\ell}}. \tag{1.4}$$

Interpretation. Da die Standardisierung in beiden Räumen simultan erfolgt, liegen alle standardisierten Gen-Vektoren *und* alle standardisierten Sample-Vektoren auf einer Sphäre in ihrem jeweiligen Raum. Dabei gilt:

- Gene, die in *vielen* Samples ähnlich stark exprimiert sind, erhalten kleine standardisierte Komponenten (typisches Rauschen).
- Gene, deren Expression auf *wenige* Samples konzentriert ist, erhalten große standardisierte Spitzenkomponenten (potenzielles Signal).

Dieses Verhalten macht $M^{\mathcal{S}}_{k-1}$ zur idealen Grundlage für die Berechnung initialer Gewichte im folgenden Schritt.

1. Initiale Achsen

- Für Gen $|g_i\rangle$ als Repräsentant: setze $|a^s\rangle := |g_i\rangle$ als initiale Sample-Achse.
- Für Sample $|s_j\rangle$ als Repräsentant: setze $|a^g\rangle := |s_j\rangle$ als initiale Gen-Achse.

2. Initiale Gewichte aus $M^{\mathcal{S}}_{k-1}$

Die initialen Gewichte werden direkt aus dem standardisierten Signal abgeleitet. Für ein Gen $|g_i\rangle$ als Repräsentant lauten die initialen Sample-Gewichte:

$$\langle e^s_j \mid w^s_{\text{initial}}\rangle \;:=\; \min\left(1,\; \frac{\left|M^{\mathcal{S}}_{k-1}(i,j)\right|}{0{,}8\cdot \max_{j'}\left|M^{\mathcal{S}}_{k-1}(i,j')\right|}\right). \tag{1.5}$$

Analog für ein Sample $|s_j\rangle$ als Repräsentant die initialen Gen-Gewichte:

$$\langle e^g_i \mid w^g_{\text{initial}}\rangle \;:=\; \min\left(1,\; \frac{\left|M^{\mathcal{S}}_{k-1}(i,j)\right|}{0{,}8\cdot \max_{i'}\left|M^{\mathcal{S}}_{k-1}(i',j)\right|}\right). \tag{1.6}$$

3. Vervollständigung der Achsen (Gl. 6 & 7)

Die Gen-Achse entsteht durch gewichtete Projektion aller anderen Gene auf das initiale Sample, und umgekehrt:

$$\langle e^g_{i'} \mid a^g\rangle \;:=\; \frac{\langle g_{i'} \mid g_i\rangle^0_{|w^s_{\text{initial}}\rangle}}{\|w^s_{\text{initial}}\|}\,, \tag{1.7}$$

$$\langle e^s_{j'} \mid a^s\rangle \;:=\; \frac{\langle s_{j'} \mid s_j\rangle^0_{|w^g_{\text{initial}}\rangle}}{\|w^g_{\text{initial}}\|}\,. \tag{1.8}$$

Hierbei ist die gewichtete Projektion definiert als (Gl. 4):

$$\langle x \mid a\rangle^0_{|w\rangle} \;:=\; \frac{\langle w\cdot x \mid w\cdot a\rangle}{\|w\cdot a\|}\,. \tag{1.9}$$

4. Erste Korrelationen und p-Werte (Gl. 8)

Unzentrierte gewichtete Korrelation (Gl. 3):

$$[x \mid a]_{|w\rangle} \;:=\; \frac{\langle w \cdot x \mid w \cdot a\rangle}{\|w \cdot x\| \cdot \|w \cdot a\|}\,. \tag{1.10}$$

Korrelationen aller Gene mit der Sample-Achse und aller Samples mit der Gen-Achse:

$$\langle e^g_{i'} \mid r^g\rangle \;=\; [g_{i'} \mid a^s]_{|w^s_{\text{initial}}\rangle}, \tag{1.11}$$

$$\langle e^s_{j'} \mid r^s\rangle \;=\; [s_{j'} \mid a^g]_{|w^g_{\text{initial}}\rangle}. \tag{1.12}$$

p-Werte via t-Statistik (Supp. Note 2):

$$t \;=\; \frac{r\sqrt{\nu}}{\sqrt{1-r^2}}\,, \qquad \nu^s = \sum_j \langle e^s_j \mid w^s\rangle - 2, \quad \nu^g = \sum_i \langle e^g_i \mid w^g\rangle - 2. \tag{1.13}$$

Der p-Wert integriert nur den jeweiligen Schwanz der t-Verteilung mit ν Freiheitsgraden (einseitig entsprechend dem Vorzeichen von t).

5. Signature Focus $|w^g\rangle$, $|w^s\rangle$ (Gl. 17–20)

Hilfsgrößen (kombiniert aus Korrelation und p-Wert):

$$x^s_j \;:=\; \Big|\langle e^s_j \mid r^s\rangle\Big| \cdot \Big(1 - \langle e^s_j \mid p^s\rangle\Big)^2, \tag{1.14}$$

$$x^g_i \;:=\; \Big|\langle e^g_i \mid r^g\rangle\Big| \cdot \Big(1 - \langle e^g_i \mid p^g\rangle\Big)^2. \tag{1.15}$$

Normierung auf Maximalwert (Werte $\geq$ 50% des Maximums erhalten volles Gewicht):

$$y^s_j \;:=\; \min\!\left(1,\; \frac{x^s_j}{\frac{1}{2}\max_{j'} x^s_{j'}}\right), \tag{1.16}$$

$$y^g_i \;:=\; \min\!\left(1,\; \frac{x^g_i}{\frac{1}{2}\max_{i'} x^g_{i'}}\right). \tag{1.17}$$

Spezifizitätsfilter (Nullsetzung schwacher/unsignifikanter Einträge):

$$\langle e^s_j \mid w^s\rangle \;:=\; \begin{cases} y^s_j & \text{falls } y^s_j \;\geq\; \dfrac{2}{3n}\Big|\{j' : y^s_{j'} \geq y^s_j\}\Big|, \\ 0 & \text{sonst,} \end{cases} \tag{1.18}$$

$$\langle e^g_i \mid w^g\rangle \;:=\; \begin{cases} y^g_i & \text{falls } y^g_i \;\geq\; \dfrac{2}{3m}\Big|\{i' : y^g_{i'} \geq y^g_i\}\Big|, \\ 0 & \text{sonst.} \end{cases} \tag{1.19}$$

Zusätzlich wird der *extended signature focus* $|v^g\rangle$, $|v^s\rangle$ analog berechnet, jedoch mit einer oberen Schwelle von 100% (statt 50%) und einer unteren Spezifizitätsschwelle von 0,4 (statt $\frac{2}{3}$). Er dient der Größenschätzung der Signatur.

6. Verfeinerte Achsen

Mit den neuen Gewichten werden die Achsen erneut konstruiert:

$$\langle e^g_{i'} \mid a^g \rangle \;\leftarrow\; \frac{\langle g_{i'} \mid g_i \rangle^0_{|w^s\rangle}}{\|w^s\|}\,, \tag{1.20}$$

$$\langle e^s_{j'} \mid a^s \rangle \;\leftarrow\; \frac{\langle s_{j'} \mid s_j \rangle^0_{|w^g\rangle}}{\|w^g\|}\,. \tag{1.21}$$

7. Verfeinerte Korrelationen und *p*-Werte

$$\langle e^g_{i'} \mid r^g \rangle \;=\; [g_{i'} \mid a^s]_{|w^s\rangle}, \tag{1.22}$$

$$\langle e^s_{j'} \mid r^s \rangle \;=\; [s_{j'} \mid a^g]_{|w^g\rangle}. \tag{1.23}$$

p-Werte $|p^g\rangle$, $|p^s\rangle$ werden wie in Abschnitt 4 aktualisiert.

8. Signaturfunktional (Gl. 22–26)

Aus dem *extended signature focus* $|v^g\rangle$, $|v^s\rangle$:

Größenschätzung:

$$m_k \;\coloneqq\; \sum_{i=1}^{m} v^g_i, \qquad n_k \;\coloneqq\; \sum_{j=1}^{n} v^s_j. \tag{1.24}$$

Kombinierte Signaturgröße (90 % Gewicht auf die kleinere Dimension, um schmale Streifen-Artefakte zu benachteiligen):

$$s_k \;\coloneqq\; \sqrt{\min(m_k,\, n_k)^{0{,}9} \cdot \max(m_k,\, n_k)^{0{,}1}}. \tag{1.25}$$

Mittlere absolute Korrelationen:

$$\bar{r}^g_k \;\coloneqq\; \frac{\sum_{i=1}^{m} v^g_i\, |r^g_i|}{m_k}\,, \qquad \bar{r}^s_k \;\coloneqq\; \frac{\sum_{j=1}^{n} v^s_j\, |r^s_j|}{n_k}\,. \tag{1.26}$$

Kombinierte mittlere Korrelation:

$$r_k \;\coloneqq\; \frac{n_k\, \bar{r}^g_k + m_k\, \bar{r}^s_k}{n_k + m_k}\,. \tag{1.27}$$

Signaturfunktional (angelehnt an die t-Statistik einer Korrelation, um konsistente Signaturen zu bevorzugen):

$$\mathcal{E}[|a^g\rangle, |a^s\rangle] \;\coloneqq\; s_k \cdot \frac{r_k}{\sqrt{1 - r_k^2}}\,. \tag{1.28}$$

9. Qualifikation und Auswahl

Ein Achsenpaar $(|a^g\rangle, |a^s\rangle)$ qualifiziert sich, wenn alle folgenden Bedingungen erfüllt sind:

- **Signalstärke:** $p_s \leq \alpha_s$ mit Bonferroni-korrigiertem Schwellwert $\alpha_s = 10^{-5}/(m+n)$.
- **Korrelationen:** $p_r \leq \alpha_r$ mit $\alpha_r = 10^{-10}/(m+n)$.
- **Mindestkonsistenz:** $r_k \geq 0{,}4$.
- **Mindestgröße:** $m_k \geq 0{,}5 \log_2 n$ und $n_k \geq 0{,}5 \log_2 m$.

Aus allen qualifizierten Achsenpaaren wird dasjenige mit maximalem $\mathcal{E}$ an **Step 2** übergeben. Falls kein Gen und kein Sample qualifiziert, terminiert SDCM.