Contents

Contents 1

1 Methoden 2

1 Methoden

Step 1 – Vollständige mathematische Struktur

Für jedes Gen $|g_i\rangle$ bzw. Sample $|s_j\rangle$ als initiales Repräsentant wird folgende Prozedur durchgeführt.

Das standardisierte Restsignal M^s_{k-1}

Zu Beginn jeder Detektionsiteration k liegt das aktuelle Restsignal $M_{k-1} \in \mathbb{R}^{m\times n}$ vor (für $k = 1$ ist das die Eingabematrix M_0). Daraus wird das *standardisierte Signal* M^s_{k-1} berechnet, das als Grundlage für die initialen Gewichte dient.

Motivation. In einem hochdimensionalen Raum können Gene oder Samples, die in allen Dimensionen ähnlich stark exprimiert sind, leicht fälschlicherweise als Signaturkandidaten erscheinen, sie haben eine hohe ℓ^2-Norm, obwohl ihr Signal gleichmässig über alle Dimensionen verteilt ist und damit typisch für Rauschen ist. Das Ziel der Standardisierung ist es, alle Gen-Vektoren *und* alle Sample-Vektoren gleichzeitig auf Einheitslänge bezüglich der unzentrierten Varianz zu bringen. Dadurch erhalten Gene bzw. Samples, deren Signal auf wenige Dimensionen konzentriert ist, einen höheren relativen Standardisierungskoeffizienten als solche mit gleichförmig verteiltem Signal (Rauschen). Der folgende Ansatz verfolgt über Konvergenz die gleichzeitige Normierung der Spalten und Zeilen der Matrix $M_{k-1} \in \mathbb{R}^{m\times n}$.

Konstruktion (Konvergenzschleife mit Index ℓ). Starte mit $M_{k-1,1} := M_{k-1}$. In jeder Iteration ℓ:

- Berechne die unzentrierten empirischen Varianzen aller Sample-Spalten:

$$\langle e^s_j \mid v^s_\ell \rangle \;:=\; \frac{1}{m}\sum_{i=1}^{m}\langle e^g_i \mid s_{j,\ell}\rangle^2 \;=\; \frac{1}{m}\sum_{i=1}^{m} M_{k-1,\ell}(i,j)^2. \tag{1.1}$$

- Berechne analog die un-zentrierten Varianzen aller Gen-Zeilen:

$$\langle e^g_i \mid v^g_\ell \rangle \;:=\; \frac{1}{n}\sum_{j=1}^{n}\langle e^s_j \mid g_{i,\ell}\rangle^2 \;=\; \frac{1}{n}\sum_{j=1}^{n} M_{k-1,\ell}(i,j)^2. \tag{1.2}$$

- Aktualisiere komponentenweise durch Division durch die Quadratwurzeln des äußeren Produkts $|v^g_\ell\rangle \otimes |v^s_\ell\rangle$:

$$M_{k-1,\ell+1}(i,j) \;:=\; \frac{M_{k-1,\ell}(i,j)}{\sqrt{\langle e^g_i \mid v^g_\ell\rangle \cdot \langle e^s_j \mid v^s_\ell\rangle}}. \tag{1.3}$$

Iteriere bis alle unzentrierten Varianzen (Norm Spalten sowie Zeilen simultan) aller Gene und Samples gleich 1 sind (Konvergenziteration $\hat{\ell}$). Das Ergebnis ist

$$M^{\mathcal{S}}_{k-1} \;\coloneqq\; M_{k-1,\hat{\ell}}. \tag{1.4}$$

Interpretation. Da die Standardisierung in beiden Räumen simultan erfolgt, liegen alle standardisierten Gen-Vektoren *und* alle standardisierten Sample-Vektoren auf einer Sphäre in ihrem jeweiligen Raum. Dabei gilt:

- Gene, die in *vielen* Samples ähnlich stark exprimiert sind, erhalten kleine standardisierte Komponenten (typisches Rauschen).
- Gene, deren Expression auf *wenige* Samples konzentriert ist, erhalten große standardisierte Spitzenkomponenten (potenzielles Signal).

Dieses Verhalten macht $M^{\mathcal{S}}_{k-1}$ zur idealen Grundlage für die Berechnung initialer Gewichte im folgenden Schritt.

1. Initiale Achsen

- Für Gen $|g_i\rangle$ als Repräsentant: setze $|a^s\rangle \coloneqq |g_i\rangle$ als initiale Sample-Achse.
- Für Sample $|s_j\rangle$ als Repräsentant: setze $|a^g\rangle \coloneqq |s_j\rangle$ als initiale Gen-Achse.

2. Initiale Gewichte aus $M^{\mathcal{S}}_{k-1}$

Die initialen Gewichte werden direkt aus dem standardisierten Signal abgeleitet. Für ein Gen $|g_i\rangle$ als Repräsentant lauten die initialen Sample-Gewichte:

$$\langle e^s_j \mid w^s_{\text{initial}}\rangle \;\coloneqq\; \min\!\left(1,\; \frac{\left|M^{\mathcal{S}}_{k-1}(i,j)\right|}{0{,}8\cdot \max_{j'}\left|M^{\mathcal{S}}_{k-1}(i,j')\right|}\right). \tag{1.5}$$

Analog für ein Sample $|s_j\rangle$ als Repräsentant die initialen Gen-Gewichte:

$$\langle e^g_i \mid w^g_{\text{initial}}\rangle \;\coloneqq\; \min\!\left(1,\; \frac{\left|M^{\mathcal{S}}_{k-1}(i,j)\right|}{0{,}8\cdot \max_{i'}\left|M^{\mathcal{S}}_{k-1}(i',j)\right|}\right). \tag{1.6}$$

3. Vervollständigung der Achsen (Gl. 6 & 7)

Die Gen-Achse entsteht durch gewichtete Projektion aller anderen Gene auf das initiale Sample, und umgekehrt:

$$\langle e^g_{i'} \mid a^g\rangle \;\coloneqq\; \frac{\langle g_{i'} \mid g_i\rangle^0_{|w^s_{\text{initial}}\rangle}}{\|w^s_{\text{initial}}\|}\,, \tag{1.7}$$

$$\langle e^s_{j'} \mid a^s\rangle \;\coloneqq\; \frac{\langle s_{j'} \mid s_j\rangle^0_{|w^g_{\text{initial}}\rangle}}{\|w^g_{\text{initial}}\|}\,. \tag{1.8}$$

Hierbei ist die gewichtete Projektion definiert als (Gl. 4):

$$\langle x \mid a \rangle^0_{|w\rangle} \;:=\; \frac{\langle w \odot x \mid w \odot a \rangle}{\| \, w \odot a \, \|} \;=\; \frac{\sum_k w_k^2 \, x_k \, a_k}{\sqrt{\sum_k w_k^2 \, a_k^2}} \,. \tag{1.9}$$

Dabei bezeichnet $\odot$ das komponentenweise Produkt (Hadamard-Produkt) zweier Vektoren, d. h.

$$w \odot x \;=\; (w_1 x_1,\; w_2 x_2,\; \ldots,\; w_n x_n).$$

4. Erste Korrelationen und *p*-Werte (Gl. 8)

Unzentrierte gewichtete Korrelation (Gl. 3):

$$[x \mid a]_{|w\rangle} \;:=\; \frac{\langle w \cdot x \mid w \cdot a \rangle}{\|w \cdot x\| \cdot \|w \cdot a\|} \;=\; \frac{\sum_k w_k^2 \, x_k \, a_k}{\sqrt{\sum_k w_k^2 \, a_k^2} \cdot \sqrt{\sum_k w_k^2 \, x_k^2}} \;=\; \cos(\Theta) \tag{1.10}$$

Korrelationen aller Gene mit der Sample-Achse und aller Samples mit der Gen-Achse:

$$\langle e^g_{i'} \mid r^g \rangle \;=\; [g_{i'} \mid a^s]_{|w^s_{\text{initial}}\rangle}, \tag{1.11}$$

$$\langle e^s_{j'} \mid r^s \rangle \;=\; [s_{j'} \mid a^g]_{|w^g_{\text{initial}}\rangle}. \tag{1.12}$$

Die *p*-Werte - Supplementary Note 2

In niedrigdimensionalen Räumen, d.h. wenn der effektive Signature Focus $|w^s\rangle$ bzw. $|w^g\rangle$ nur wenige Samples oder Gene mit hohem Gewicht enthält, ist es wahrscheinlicher, zufällig hohe Korrelationswerte zu erhalten, da Vektoren in niedrigdimensionalen Räumen geometrisch kaum Möglichkeiten haben, weit auseinanderzuliegen. Um den Einfluss solcher hohen aber insignifikanten Korrelationen zu reduzieren, wird für jede Korrelation r ein p-Wert berechnet.

Für eine gewöhnliche (ungewichtete) Pearson-Korrelation r über n Datenpunkte folgt unter der Nullhypothese (keine echte Korrelation) die Teststatistik

$$t \;=\; \frac{r\sqrt{\nu}}{\sqrt{1-r^2}} \tag{1.13}$$

exakt einer Student-t-Verteilung mit ν Freiheitsgraden, wobei $\nu = n - 2$. Die Subtraktion von 2 entsteht, weil beim Schätzen der Korrelation zwei Parameter aus den Daten geschätzt werden müssen: der Mittelwert von x und der Mittelwert von y. Jeder geschätzte Parameter verbraucht einen Freiheitsgrad, sodass nach dieser Schätzung nur noch $n - 2$ wirklich unabhängige Informationen verbleiben.

Im gewichteten Fall trägt nicht jedes Sample gleich viel zur Korrelationsberechnung bei. Angenommen, man hat $n = 100$ Samples, aber der Signature Focus enthält nur 3 Samples mit Gewicht $w_j \approx 1$ und die restlichen 97 haben Gewicht $w_j \approx 0$.

Würde man $\nu = n - 2 = 98$ verwenden, würde dem t-Test fälschlicherweise suggeriert, dass 98 unabhängige Informationen vorliegen, obwohl die Korrelation effektiv nur auf 3 Datenpunkten basiert. Dies würde zu künstlich kleinen p-Werten führen und damit Signifikanz vortäuschen, wo keine ist. Ein Sample mit Gewicht $w_j = 0{,}5$ liefert daher nur halb so viel Information wie eines mit $w_j = 1$. Die tatsächlich genutzte Information wird durch die effektive Stichprobengröße $\sum_j w_j$ ausgedrückt, und die Freiheitsgrade werden entsprechend ersetzt:

$$\nu^s = \sum_j \langle e_j^s \mid w^s \rangle - 2, \qquad \nu^g = \sum_i \langle e_i^g \mid w^g \rangle - 2. \tag{1.14}$$

Die Wahrscheinlichkeitsdichte $\rho_\nu(t)$ der Student-t-Verteilung gibt an, wie wahrscheinlich ein bestimmter Wert t allein durch Zufall auftritt, wenn die Nullhypothese gilt:

$$\rho_\nu(t) = \frac{\Gamma\left(\frac{\nu+1}{2}\right)}{\sqrt{\nu\pi}\,\Gamma\left(\frac{\nu}{2}\right)} \left(1 + \frac{t^2}{\nu}\right)^{-\frac{\nu+1}{2}}. \tag{1.15}$$

Sie ist symmetrisch um 0 und besitzt für kleine ν ausgeprägte Ränder (sogenannte *fat tails*), da bei wenigen Datenpunkten extreme t-Werte durch Zufall häufiger auftreten. Der p-Wert ist die Fläche unter ρ_ν ab dem beobachteten t bis in den jeweiligen Schwanz, also die Wahrscheinlichkeit, durch Zufall einen mindestens so extremen t-Wert zu erhalten. Da p-Werte hier die Wahrscheinlichkeit quantifizieren, durch Zufall eine gleichgerichtete Korrelation mindestens dieser Stärke zu beobachten, integriert man nur den entsprechenden einseitigen Schwanz (Supp. Note 2):

$$p = \int_t^\infty \rho_\nu(t')\,dt' \quad \text{für } t \geq 0, \qquad p = \int_{-\infty}^t \rho_\nu(t')\,dt' \quad \text{für } t \leq 0. \tag{1.16}$$

5. Signature Focus $|w^g\rangle$, $|w^s\rangle$ (Gl. 17–20)

Hilfsgrößen (kombiniert aus Korrelation und p-Wert):

$$x_j^s := \left|\langle e_j^s \mid r^s \rangle\right| \cdot \left(1 - \langle e_j^s \mid p^s \rangle\right)^2, \tag{1.17}$$

$$x_i^g := \left|\langle e_i^g \mid r^g \rangle\right| \cdot \left(1 - \langle e_i^g \mid p^g \rangle\right)^2. \tag{1.18}$$

Normierung auf Maximalwert (Werte $\geq 50\%$ des Maximums erhalten volles Gewicht):

$$y_j^s := \min\left(1,\ \frac{x_j^s}{\frac{1}{2}\max_{j'} x_{j'}^s}\right), \tag{1.19}$$

$$y_i^g := \min\left(1,\ \frac{x_i^g}{\frac{1}{2}\max_{i'} x_{i'}^g}\right). \tag{1.20}$$

Spezifizitätsfilter (Nullsetzung schwacher/unsignifikanter Einträge):

$$\langle e_j^s \mid w^s \rangle \;:=\; \begin{cases} y_j^s & \text{falls } y_j^s \;\geq\; \dfrac{2}{3n}\Big|\{j' : y_{j'}^s \geq y_j^s\}\Big|, \\ 0 & \text{sonst,} \end{cases} \tag{1.21}$$

$$\langle e_i^g \mid w^g \rangle \;:=\; \begin{cases} y_i^g & \text{falls } y_i^g \;\geq\; \dfrac{2}{3m}\Big|\{i' : y_{i'}^g \geq y_i^g\}\Big|, \\ 0 & \text{sonst.} \end{cases} \tag{1.22}$$

Zusätzlich wird der *extended signature focus* $|v^g\rangle$, $|v^s\rangle$ analog berechnet, jedoch mit einer oberen Schwelle von 100% (statt 50%) und einer unteren Spezifizitätsschwelle von 0,4 (statt $\frac{2}{3}$). Er dient der Größenschätzung der Signatur.

6. Verfeinerte Achsen

Mit den neuen Gewichten werden die Achsen erneut konstruiert:

$$\langle e_{i'}^g \mid a^g \rangle \;\leftarrow\; \frac{\langle g_{i'} \mid g_i \rangle^0_{|w^s\rangle}}{\|w^s\|}\,, \tag{1.23}$$

$$\langle e_{j'}^s \mid a^s \rangle \;\leftarrow\; \frac{\langle s_{j'} \mid s_j \rangle^0_{|w^g\rangle}}{\|w^g\|}\,. \tag{1.24}$$

7. Verfeinerte Korrelationen und *p*-Werte

$$\langle e_{i'}^g \mid r^g \rangle \;=\; [g_{i'} \mid a^s]_{|w^s\rangle}, \tag{1.25}$$

$$\langle e_{j'}^s \mid r^s \rangle \;=\; [s_{j'} \mid a^g]_{|w^g\rangle}. \tag{1.26}$$

p-Werte $|p^g\rangle$, $|p^s\rangle$ werden wie in Abschnitt 4 aktualisiert.

8. Signaturfunktional (Gl. 22–26)

Aus dem *extended signature focus* $|v^g\rangle$, $|v^s\rangle$:

Größenschätzung:

$$m_k \;:=\; \sum_{i=1}^{m} v_i^g, \qquad n_k \;:=\; \sum_{j=1}^{n} v_j^s. \tag{1.27}$$

Kombinierte Signaturgröße (90 % Gewicht auf die kleinere Dimension, um schmale Streifen-Artefakte zu benachteiligen):

$$s_k \;:=\; \sqrt{\min(m_k,\, n_k)^{0,9} \cdot \max(m_k,\, n_k)^{0,1}}. \tag{1.28}$$

Mittlere absolute Korrelationen:

$$\bar{r}_k^g \;:=\; \frac{\sum_{i=1}^{m} v_i^g \, |r_i^g|}{m_k}\,, \qquad \bar{r}_k^s \;:=\; \frac{\sum_{j=1}^{n} v_j^s \, |r_j^s|}{n_k}\,. \tag{1.29}$$

Kombinierte mittlere Korrelation:

$$r_k \;:=\; \frac{n_k \, \bar{r}_k^g + m_k \, \bar{r}_k^s}{n_k + m_k}\,. \tag{1.30}$$

Signaturfunktional (angelehnt an die t-Statistik einer Korrelation, um konsistente Signaturen zu bevorzugen):

$$\xi[|a^g\rangle, |a^s\rangle] \;:=\; s_k \cdot \frac{r_k}{\sqrt{1 - r_k^2}}\,. \tag{1.31}$$

9. Qualifikation und Auswahl

Ein Achsenpaar $(|a^g\rangle, |a^s\rangle)$ qualifiziert sich, wenn alle folgenden Bedingungen erfüllt sind:

- **Signalstärke:** $p_s \leq \alpha_s$ mit Bonferroni-korrigiertem Schwellwert $\alpha_s = 10^{-5}/(m+n)$.
- **Korrelationen:** $p_r \leq \alpha_r$ mit $\alpha_r = 10^{-10}/(m+n)$.
- **Mindestkonsistenz:** $r_k \geq 0{,}4$.
- **Mindestgröße:** $m_k \geq 0{,}5 \log_2 n$ und $n_k \geq 0{,}5 \log_2 m$.

Aus allen qualifizierten Achsenpaaren wird dasjenige mit maximalem $\mathcal{E}$ an **Step 2** übergeben. Falls kein Gen und kein Sample qualifiziert, terminiert SDCM.