Contents

Contents **1**

1 Methoden **2**

1.1 Step 1 – Search Strategy 2

1.2 Step 2 – Signature axes via maximization principle 8

1.3 Step 3 – Bi-monotonic regression and smoothening 10

1.4 Step 4 – Signature signal E_k and its dissection 14

1 Methoden

1.1 Step 1 – Search Strategy

Für jedes Gen $|g_i\rangle$ bzw. Sample $|s_j\rangle$ als initiales Repräsentant wird folgende Prozedur durchgeführt.

Das standardisierte Restsignal M^s_{k-1}

Zu Beginn jeder Detektionsiteration k liegt das aktuelle Restsignal $M_{k-1} \in \mathbb{R}^{m\times n}$ vor (für $k = 1$ ist das die Eingabematrix M_0). Daraus wird das *standardisierte Signal* M^s_{k-1} berechnet, das als Grundlage für die initialen Gewichte dient.

Motivation. In einem hochdimensionalen Raum können Gene oder Samples, die in allen Dimensionen ähnlich stark exprimiert sind, leicht fälschlicherweise als Signaturkandidaten erscheinen, sie haben eine hohe ℓ^2-Norm, obwohl ihr Signal gleichmässig über alle Dimensionen verteilt ist und damit typisch für Rauschen ist. Das Ziel der Standardisierung ist es, alle Gen-Vektoren *und* alle Sample-Vektoren gleichzeitig auf Einheitslänge bezüglich der unzentrierten Varianz zu bringen. Dadurch erhalten Gene bzw. Samples, deren Signal auf wenige Dimensionen konzentriert ist, einen höheren relativen Standardisierungskoeffizienten als solche mit gleichförmig verteiltem Signal (Rauschen). Der folgende Ansatz verfolgt über Konvergenz die gleichzeitige Normierung der Spalten und Zeilen der Matrix $M_{k-1} \in \mathbb{R}^{m\times n}$.

Konstruktion (Konvergenzschleife mit Index ℓ). Starte mit $M_{k-1,1} := M_{k-1}$. In jeder Iteration ℓ:

- Berechne die unzentrierten empirischen Varianzen aller Sample-Spalten:

$$\langle e^s_j \mid v^s_\ell \rangle \;:=\; \frac{1}{m}\sum_{i=1}^{m}\langle e^g_i \mid s_{j,\ell}\rangle^2 \;=\; \frac{1}{m}\sum_{i=1}^{m} M_{k-1,\ell}(i,j)^2. \tag{1.1}$$

- Berechne analog die un-zentrierten Varianzen aller Gen-Zeilen:

$$\langle e^g_i \mid v^g_\ell \rangle \;:=\; \frac{1}{n}\sum_{j=1}^{n}\langle e^s_j \mid g_{i,\ell}\rangle^2 \;=\; \frac{1}{n}\sum_{j=1}^{n} M_{k-1,\ell}(i,j)^2. \tag{1.2}$$

- Aktualisiere komponentenweise durch Division durch die Quadratwurzeln des äußeren Produkts $|v^g_\ell\rangle \otimes |v^s_\ell\rangle$:

$$M_{k-1,\ell+1}(i,j) \;:=\; \frac{M_{k-1,\ell}(i,j)}{\sqrt{\langle e^g_i \mid v^g_\ell\rangle \cdot \langle e^s_j \mid v^s_\ell\rangle}}. \tag{1.3}$$

Iteriere bis alle unzentrierten Varianzen (Norm Spalten sowie Zeilen simultan) aller Gene und Samples gleich 1 sind (Konvergenziteration $\hat{\ell}$). Das Ergebnis ist

$$M^{\mathcal{S}}_{k-1} \;\coloneqq\; M_{k-1,\hat{\ell}}. \tag{1.4}$$

Interpretation. Da die Standardisierung in beiden Räumen simultan erfolgt, liegen alle standardisierten Gen-Vektoren *und* alle standardisierten Sample-Vektoren auf einer Sphäre in ihrem jeweiligen Raum. Dabei gilt:

- Gene, die in *vielen* Samples ähnlich stark exprimiert sind, erhalten kleine standardisierte Komponenten (typisches Rauschen).
- Gene, deren Expression auf *wenige* Samples konzentriert ist, erhalten große standardisierte Spitzenkomponenten (potenzielles Signal).

Dieses Verhalten macht $M^{\mathcal{S}}_{k-1}$ zur idealen Grundlage für die Berechnung initialer Gewichte im folgenden Schritt.

1.1.1 Initiale Achsen

- Für Gen $|g_i\rangle$ als Repräsentant: setze $|a^s\rangle \coloneqq |g_i\rangle$ als initiale Sample-Achse.
- Für Sample $|s_j\rangle$ als Repräsentant: setze $|a^g\rangle \coloneqq |s_j\rangle$ als initiale Gen-Achse.

1.1.2. Initiale Gewichte aus $M^{\mathcal{S}}_{k-1}$

Die initialen Gewichte werden direkt aus dem standardisierten Signal abgeleitet. Für ein Gen $|g_i\rangle$ als Repräsentant lauten die initialen Sample-Gewichte:

$$\langle e^s_j \mid w^s_{\text{initial}}\rangle \;\coloneqq\; \min\!\left(1,\; \frac{\left|M^{\mathcal{S}}_{k-1}(i,j)\right|}{0{,}8\cdot \max_{j'}\left|M^{\mathcal{S}}_{k-1}(i,j')\right|}\right). \tag{1.5}$$

Analog für ein Sample $|s_j\rangle$ als Repräsentant die initialen Gen-Gewichte:

$$\langle e^g_i \mid w^g_{\text{initial}}\rangle \;\coloneqq\; \min\!\left(1,\; \frac{\left|M^{\mathcal{S}}_{k-1}(i,j)\right|}{0{,}8\cdot \max_{i'}\left|M^{\mathcal{S}}_{k-1}(i',j)\right|}\right). \tag{1.6}$$

1.1.3 Vervollständigung der Achsen (Gl. 6 & 7)

Die Gen-Achse entsteht durch gewichtete Projektion aller anderen Gene auf das initiale Sample, und umgekehrt:

$$\langle e^g_{i'} \mid a^g\rangle \;\coloneqq\; \frac{\langle g_{i'} \mid g_i\rangle^0_{|w^s_{\text{initial}}\rangle}}{\|w^s_{\text{initial}}\|}\,, \tag{1.7}$$

$$\langle e^s_{j'} \mid a^s\rangle \;\coloneqq\; \frac{\langle s_{j'} \mid s_j\rangle^0_{|w^g_{\text{initial}}\rangle}}{\|w^g_{\text{initial}}\|}\,. \tag{1.8}$$

Hierbei ist die gewichtete Projektion definiert als (Gl. 4):

$$\langle x \mid a \rangle^0_{|w\rangle} \;:=\; \frac{\langle w \odot x \mid w \odot a \rangle}{\| \, w \odot a \, \|} \;=\; \frac{\sum_k w_k^2 \, x_k \, a_k}{\sqrt{\sum_k w_k^2 \, a_k^2}} \,. \tag{1.9}$$

Dabei bezeichnet $\odot$ das komponentenweise Produkt (Hadamard-Produkt) zweier Vektoren, d. h.

$$w \odot x \;=\; (w_1 x_1,\; w_2 x_2,\; \ldots,\; w_n x_n).$$

1.1.4 Erste Korrelationen und p-Werte (Gl. 8)

Unzentrierte gewichtete Korrelation (Gl. 3):

$$[x \mid a]_{|w\rangle} \;:=\; \frac{\langle w \cdot x \mid w \cdot a \rangle}{\|w \cdot x\| \cdot \|w \cdot a\|} \;=\; \frac{\sum_k w_k^2 \, x_k \, a_k}{\sqrt{\sum_k w_k^2 \, a_k^2} \cdot \sqrt{\sum_k w_k^2 \, x_k^2}} \;=\; \cos(\Theta) \tag{1.10}$$

Korrelationen aller Gene mit der Sample-Achse und aller Samples mit der Gen-Achse:

$$\langle e^g_{i'} \mid r^g \rangle \;=\; [g_{i'} \mid a^s]_{|w^s_{\text{initial}}\rangle}, \tag{1.11}$$

$$\langle e^s_{j'} \mid r^s \rangle \;=\; [s_{j'} \mid a^g]_{|w^g_{\text{initial}}\rangle}. \tag{1.12}$$

Die p-Werte - Supplementary Note 2

In niedrigdimensionalen Räumen, d.h. wenn der effektive Signature Focus $|w^s\rangle$ bzw. $|w^g\rangle$ nur wenige Samples oder Gene mit hohem Gewicht enthält, ist es wahrscheinlicher, zufällig hohe Korrelationswerte zu erhalten, da Vektoren in niedrigdimensionalen Räumen geometrisch kaum Möglichkeiten haben, weit auseinanderzuliegen. Um den Einfluss solcher hohen aber insignifikanten Korrelationen zu reduzieren, wird für jede Korrelation r ein p-Wert berechnet.

Für eine gewöhnliche (ungewichtete) Pearson-Korrelation r über n Datenpunkte folgt unter der Nullhypothese (keine echte Korrelation) die Teststatistik

$$t^{\square} = \frac{r^{\square}\sqrt{\nu^{\square}}}{\sqrt{1-(r^{\square})^2}} \tag{1.13}$$

exakt einer Student-t-Verteilung mit ν Freiheitsgraden, wobei $\nu = n - 2$ und $\square$ markiert Index der g-Gene und s-Samples. Die Subtraktion von 2 entsteht, weil beim Schätzen der Korrelation zwei Parameter aus den Daten geschätzt werden müssen. Der Mittelwert von x und der Mittelwert von y. Jeder geschätzte Parameter verbraucht einen Freiheitsgrad, sodass nach dieser Schätzung nur noch $n - 2$ wirklich unabhängige Informationen verbleiben.

Im gewichteten Fall trägt nicht jedes Sample gleich viel zur Korrelationsberechnung bei. Angenommen, man hat $n = 100$ Samples, aber der Signature Focus enthält

nur 3 Samples mit Gewicht $w_j \approx 1$ und die restlichen 97 haben Gewicht $w_j \approx 0$. Würde man $\nu = n - 2 = 98$ verwenden, würde dem t-Test fälschlicherweise suggeriert, dass 98 unabhängige Informationen vorliegen, obwohl die Korrelation effektiv nur auf 3 Datenpunkten basiert. Dies würde zu künstlich kleinen p-Werten führen und damit Signifikanz vortäuschen, wo keine ist. Ein Sample mit Gewicht $w_j = 0{,}5$ liefert daher nur halb so viel Information wie eines mit $w_j = 1$. Die tatsächlich genutzte Information wird durch die effektive Stichprobengröße $\sum_j w_j$ ausgedrückt, und die Freiheitsgrade werden entsprechend ersetzt:

$$\nu^s = \sum_j \langle e_j^s \mid w^s \rangle - 2, \qquad \nu^g = \sum_i \langle e_i^g \mid w^g \rangle - 2. \tag{1.14}$$

Die Wahrscheinlichkeitsdichte $\rho_{\nu^\square}(t^\square)$ der Student-t-Verteilung gibt an, wie wahrscheinlich ein bestimmter Wert $t^\square$ allein durch Zufall auftritt, wenn die Nullhypothese gilt:

$$\rho_{\nu^\square}(t^\square) = \frac{\Gamma\left(\frac{\nu^\square+1}{2}\right)}{\sqrt{\nu^\square \pi}\,\Gamma\left(\frac{\nu^\square}{2}\right)} \left(1 + \frac{(t^\square)^2}{\nu^\square}\right)^{-\frac{\nu^\square+1}{2}}. \tag{1.15}$$

Sie ist symmetrisch um 0 und besitzt für kleine $\nu^\square$ ausgeprägte Ränder (*fat tails*), da bei wenigen Datenpunkten extreme $t^\square$-Werte durch Zufall häufiger auftreten. Der p-Wert ist die Fläche unter $\rho_{\nu^\square}$ ab dem beobachteten $t^\square$ bis in den jeweiligen Schwanz, also die Wahrscheinlichkeit, durch Zufall einen mindestens so extremen $t^\square$-Wert zu erhalten. Da p-Werte hier die Wahrscheinlichkeit quantifizieren, durch Zufall eine gleichgerichtete Korrelation mindestens dieser Stärke zu beobachten, integriert man nur den entsprechenden einseitigen Schwanz:

$$p^\square = \int_{t^\square}^{\infty} \rho_{\nu^\square}(t')\,dt' \quad \text{für } t^\square \geq 0, \qquad p^\square = \int_{-\infty}^{t^\square} \rho_{\nu^\square}(t')\,dt' \quad \text{für } t^\square \leq 0. \tag{1.16}$$

1.1.5 Signature Focus $|w^g\rangle$, $|w^s\rangle$ (Gl. 17–20)

Hilfsgrößen (kombiniert aus Korrelation und p-Wert):

$$x_j^s := \left|\langle e_j^s \mid r^s \rangle\right| \cdot \left(1 - \langle e_j^s \mid p^s \rangle\right)^2, \tag{1.17}$$

$$x_i^g := \left|\langle e_i^g \mid r^g \rangle\right| \cdot \left(1 - \langle e_i^g \mid p^g \rangle\right)^2. \tag{1.18}$$

Normierung auf Maximalwert (Werte $\geq 50\%$ des Maximums erhalten volles Gewicht):

$$y_j^s := \min\left(1,\ \frac{x_j^s}{\frac{1}{2}\max_{j'} x_{j'}^s}\right), \tag{1.19}$$

$$y_i^g := \min\left(1,\ \frac{x_i^g}{\frac{1}{2}\max_{i'} x_{i'}^g}\right). \tag{1.20}$$

Spezifizitätsfilter (Nullsetzung schwacher/unsignifikanter Einträge):

$$\langle e_j^s \mid w^s \rangle \;:=\; \begin{cases} y_j^s & \text{falls } y_j^s \;\geq\; \dfrac{2}{3n} \left|\{j' : y_{j'}^s \geq y_j^s\}\right|, \\ 0 & \text{sonst,} \end{cases} \tag{1.21}$$

$$\langle e_i^g \mid w^g \rangle \;:=\; \begin{cases} y_i^g & \text{falls } y_i^g \;\geq\; \dfrac{2}{3m} \left|\{i' : y_{i'}^g \geq y_i^g\}\right|, \\ 0 & \text{sonst.} \end{cases} \tag{1.22}$$

Zusätzlich wird der *extended signature focus* $|v^g\rangle$, $|v^s\rangle$ berechnet, dessen Gewichte dieselbe Konstruktionslogik verwenden, jedoch mit lockereren Schwellen. Während $|w^g\rangle$, $|w^s\rangle$ einen scharfen Kern identifizieren sollen (für die Achsenkonstruktion), dient $|v^g\rangle$, $|v^s\rangle$ der **Größenschätzung der Signatur** – ein zu strenger Filter würde die tatsächliche Ausdehnung des Musters systematisch unterschätzen.

Normierung (ohne Clamping auf 1, obere Schwelle 100%):

$$\tilde{y}_j^s \;:=\; \frac{x_j^s}{\max_{j'} x_{j'}^s}\,, \tag{1.23}$$

$$\tilde{y}_i^g \;:=\; \frac{x_i^g}{\max_{i'} x_{i'}^g}\,. \tag{1.24}$$

Spezifizitätsfilter (mit reduzierter Schwelle 0,4 statt $\frac{2}{3}$):

$$\langle e_j^s \mid v^s \rangle \;:=\; \begin{cases} \tilde{y}_j^s & \text{falls } \tilde{y}_j^s \;\geq\; \dfrac{0{,}4}{n} \left|\{j' : \tilde{y}_{j'}^s \geq \tilde{y}_j^s\}\right|, \\ 0 & \text{sonst,} \end{cases} \tag{1.25}$$

$$\langle e_i^g \mid v^g \rangle \;:=\; \begin{cases} \tilde{y}_i^g & \text{falls } \tilde{y}_i^g \;\geq\; \dfrac{0{,}4}{m} \left|\{i' : \tilde{y}_{i'}^g \geq \tilde{y}_i^g\}\right|, \\ 0 & \text{sonst.} \end{cases} \tag{1.26}$$

1.1.6 Verfeinerte Achsen

Mit den neuen Gewichten werden die Achsen erneut konstruiert:

$$\langle e_{i'}^g \mid a^g \rangle \;\leftarrow\; \frac{\langle g_{i'} \mid g_i \rangle^0_{|w^s\rangle}}{\|w^s\|}\,, \tag{1.27}$$

$$\langle e_{j'}^s \mid a^s \rangle \;\leftarrow\; \frac{\langle s_{j'} \mid s_j \rangle^0_{|w^g\rangle}}{\|w^g\|}\,. \tag{1.28}$$

1.1.7 Verfeinerte Korrelationen und *p*-Werte

$$\langle e_{i'}^g \mid r^g \rangle \;=\; [g_{i'} \mid a^s]_{|w^s\rangle}, \tag{1.29}$$

$$\langle e_{j'}^s \mid r^s \rangle \;=\; [s_{j'} \mid a^g]_{|w^g\rangle}. \tag{1.30}$$

p-Werte $|p^g\rangle$, $|p^s\rangle$ werden wie in Abschnitt 4 aktualisiert.

1.1.8 Signaturfunktional (Gl. 22–26)

Aus dem *extended signature focus* $|v^g\rangle$, $|v^s\rangle$:

Größenschätzung:

$$m_k \coloneqq \sum_{i=1}^{m} v_i^g, \qquad n_k \coloneqq \sum_{j=1}^{n} v_j^s. \tag{1.31}$$

Kombinierte Signaturgröße (90 % Gewicht auf die kleinere Dimension, um schmale Streifen-Artefakte zu benachteiligen):

$$s_k \coloneqq \sqrt{\min(m_k,\, n_k)^{0,9} \cdot \max(m_k,\, n_k)^{0,1}}. \tag{1.32}$$

Mittlere absolute Korrelationen:

$$\bar{r}_k^g \coloneqq \frac{\sum_{i=1}^{m} v_i^g\, |r_i^g|}{m_k}, \qquad \bar{r}_k^s \coloneqq \frac{\sum_{j=1}^{n} v_j^s\, |r_j^s|}{n_k}. \tag{1.33}$$

Kombinierte mittlere Korrelation:

$$r_k \coloneqq \frac{n_k\, \bar{r}_k^g + m_k\, \bar{r}_k^s}{n_k + m_k}. \tag{1.34}$$

Signaturfunktional (angelehnt an die t-Statistik einer Korrelation, um konsistente Signaturen zu bevorzugen):

$$\xi[|a^g\rangle, |a^s\rangle] \coloneqq s_k \cdot \frac{r_k}{\sqrt{1 - r_k^2}}. \tag{1.35}$$

1.1.9 Qualifikation und Auswahl

Ein Achsenpaar $(|a^g\rangle, |a^s\rangle)$ qualifiziert sich, wenn alle folgenden Bedingungen erfüllt sind:

- **Signalstärke:** $p_s \leq \alpha_s$ mit Bonferroni-korrigiertem Schwellwert $\alpha_s = 10^{-5}/(m+n)$.
- **Korrelationen:** $p_r \leq \alpha_r$ mit $\alpha_r = 10^{-10}/(m+n)$.
- **Mindestkonsistenz:** $r_k \geq 0{,}4$.
- **Mindestgröße:** $m_k \geq 0{,}5 \log_2 n$ und $n_k \geq 0{,}5 \log_2 m$.

Aus allen qualifizierten Achsenpaaren wird dasjenige mit maximalem ξ an **Step 2** übergeben. Falls kein Gen und kein Sample qualifiziert, terminiert SDCM.

Nicht für alle Gene oder Samples werden die Achsenpaare $|a^g\rangle, |a^s\rangle$ gesucht und $\xi[|a^g\rangle, |a^s\rangle]$ berechnet. Auswahl bestimmter Gene und Samples durch *look-ahead-Verfahren*, siehe *Supplementary Note 5*.

1.2 Step 2 – Signature axes via maximization principle

Ziel und Grundidee

Step 2 macht die in Step 1 gefundenen initialen Achsen unabhängig vom zufälligen Startvertreter, indem sukzessive weitere repräsentative Gene und Samples gesammelt und zu akkumulierten Achsen kombiniert werden, so lange bis diese gegen ein lokales Maximum des Signaturfunktionals ξ konvergieren.

Die akkumulierten Achsen nach l Repräsentanten werden mit $(|\mathbf{b}_l^g\rangle, |\mathbf{b}_l^s\rangle)$ bezeichnet. Für $l = 1$ gilt per Definition:

$$|\mathbf{b}_1^g\rangle \;:=\; |a^g\rangle, \qquad |\mathbf{b}_1^s\rangle \;:=\; |a^s\rangle, \tag{1.36}$$

mit den Korrelationen $|r_1^g\rangle$, $|r_1^s\rangle$, Gewichten $|w_1^g\rangle$, $|w_1^s\rangle$, p-Werten $|p_1^g\rangle$, $|p_1^s\rangle$ und Signaturfunktional ξ_1 direkt aus Step 1.

Iterationsschleife über $l = 1, 2, 3, \ldots$

1. Sortierung der Kandidaten. Alle Gene und Samples werden nach ihren absoluten Korrelationen zur aktuellen akkumulierten Achse $|\mathbf{b}_l^g\rangle$ bzw. $|\mathbf{b}_l^s\rangle$ absteigend sortiert:

$$\left|\langle e_{i_1}^g \mid r_l^g\rangle\right| \;\geq\; \left|\langle e_{i_2}^g \mid r_l^g\rangle\right| \;\geq\; \cdots, \tag{1.37}$$

$$\left|\langle e_{j_1}^s \mid r_l^s\rangle\right| \;\geq\; \left|\langle e_{j_2}^s \mid r_l^s\rangle\right| \;\geq\; \cdots \tag{1.38}$$

Nur die Top-Kandidaten dieser sortierten Liste werden als mögliche nächste Repräsentanten getestet.

2. Auswahl des nächsten Repräsentanten. Für jeden Top-Kandidaten werden hypothetisch die akkumulierten Achsen $|\mathbf{b}_{l+1}^g\rangle$ und $|\mathbf{b}_{l+1}^s\rangle$ nach Gl. (9) und Gl. (10) berechnet sowie die zugehörigen Korrelationen $|r_{l+1}^g\rangle$ und $|r_{l+1}^s\rangle$, p-Werte $|p_{l+1}^g\rangle$ und $|p_{l+1}^s\rangle$ und das Signaturfunktional ξ_{l+1}. Ausgewählt wird derjenige Kandidat, der ξ_{l+1} maximiert, und dieser wird zum Repräsentanten $l + 1$.

3. Akkumulation der Achsen (Gl. 9 und Gl. 10). Die neue akkumulierte Sample-Achse ist das korrelationsgewichtete arithmetische Mittel über alle bisherigen Einzel-Achsen $|a_{l'}^s\rangle$, $l' = 1, \ldots, l + 1$:

$$|\mathbf{b}_{l+1}^s\rangle \;\equiv\; \frac{\displaystyle\sum_{l'=1}^{l+1} \Big[\langle e_{l'}^s \mid \mathbf{b}_{l'}^s\rangle\Big]_{|w_{l'}^s\rangle} \cdot |a_{l'}^s\rangle}{\displaystyle\sum_{l'=1}^{l+1} \Big|\Big[\langle e_{l'}^s \mid \mathbf{b}_{l'}^s\rangle\Big]_{|w_{l'}^s\rangle}\Big|}\,. \tag{1.39}$$

Analog gilt für die Gen-Achse:

$$|\mathbf{b}^g_{l+1}\rangle \;\equiv\; \frac{\sum_{l'=1}^{l+1}\Big[\langle e^g_{l'} \mid \mathbf{b}^g_{l'}\rangle\Big]_{|w^g_{l'}\rangle} \cdot |a^g_{l'}\rangle}{\sum_{l'=1}^{l+1}\Big|\Big[\langle e^g_{l'} \mid \mathbf{b}^g_{l'}\rangle\Big]_{|w^g_{l'}\rangle}\Big|}\,. \tag{1.40}$$

Das Gewicht jedes Repräsentanten l' ist seine Korrelation zur bisherigen akkumulierten Achse. Repräsentanten, die schlecht zur akkumulierten Richtung passen, tragen kaum bei, während gut passende Repräsentanten vollen Einfluss behalten.

4. Konvergenzprüfung (Supp. Note 6). Nach jeder Aktualisierung wird geprüft, ob beide folgenden Kriterien gleichzeitig erfüllt sind.

Das erste Kriterium fordert geometrische Achsenkonvergenz. Es wird gemessen, wie stark sich die akkumulierten Achsen noch von Iteration zu Iteration verändern, als eins minus der Korrelation zur vorherigen Achse:

$$\delta^g \;\equiv\; 1 - \Big[\langle \mathbf{b}^g_l \mid \mathbf{b}^g_{l+1}\rangle\Big]_{|w^g_{l+1}\rangle}, \qquad \delta^s \;\equiv\; 1 - \Big[\langle \mathbf{b}^s_l \mid \mathbf{b}^s_{l+1}\rangle\Big]_{|w^s_{l+1}\rangle}. \tag{1.41}$$

Konvergenz liegt vor, wenn gilt:

$$\frac{\delta^g + \delta^s}{2} \;<\; 10^{-3}. \tag{1.42}$$

Dies entspricht einer Achsenähnlichkeit von mehr als 0,999. Die Konvergenz ist garantiert, da jeder neue Repräsentant die akkumulierte Achse nur noch mit einem maximalen Gewicht von $1/l$ verändern kann.

Das zweite Kriterium fordert eine Mindestanzahl an akkumulierten Repräsentanten:

$$l \;\geq\; \min\Big(15,\; 0{,}2 \cdot m_k\Big) \qquad \text{und} \qquad l \;\geq\; \min\Big(15,\; 0{,}2 \cdot n_k\Big). \tag{1.43}$$

Dies schützt vor zufälliger Frühkonvergenz, etwa wenn zwei nahezu identische Startgene vorliegen, sodass die Mindestanzahl sicherstellt, dass die Achse auf einer ausreichend breiten Basis von Repräsentanten beruht.

Sind beide Kriterien erfüllt, wird die Iteration abgebrochen und $\hat{l}$ ist erreicht. Andernfalls wird mit der Suche nach dem nächsten Repräsentanten fortgefahren, beginnend wieder bei Schritt 1.

Ergebnis von Step 2

Die finalen akkumulierten Achsen bei $\hat{l}$,

$$\Big(|\mathbf{b}^g_{\hat{l}}\rangle,\; |\mathbf{b}^s_{\hat{l}}\rangle\Big), \tag{1.44}$$

stellen die lineare Approximation der zugrundeliegenden Signaturinteraktion dar und werden an Step 3 übergeben.

1.3 Step 3 – Bi-monotonic regression and smoothening

Überblick

Step 3 approximiert den Beitrag der gefundenen Signatur k zur Signalmatrix M_{k-1} durch eine *bi-monotone* Darstellung. Das Signal soll sowohl in Genrichtung als auch in Samplerichtung monoton sein – passend zur Signaturstruktur. Es gibt zwei verschachtelte Loops:

- **Äußerer Loop** (Index o): berechnet Signaturstärken und sortiert die Matrix neu.
- **Innerer Loop** (Index q): führt die eigentliche bi-monotone Regression durch.

Äußerer Loop (Index o)

Schritt 1: Signaturstärken berechnen. Für die erste Iteration $o = 1$ sind die Signaturstärken direkt die gewichteten Projektionen auf die Signaturachsen:

$$\langle e_i^g \mid u_{k,1}^g \rangle \;\coloneqq\; \frac{\langle g_i \mid b_{\hat{l}}^s \rangle^0_{|w_{\hat{l}}^s\rangle}}{\|w_{\hat{l}}^s\|}\,, \tag{1.45}$$

$$\langle e_j^s \mid u_{k,1}^s \rangle \;\coloneqq\; \frac{\langle s_j \mid b_{\hat{l}}^g \rangle^0_{|w_{\hat{l}}^g\rangle}}{\|w_{\hat{l}}^g\|}\,. \tag{1.46}$$

Für $o > 1$ werden statt der Achsen die *Signaturkurven* aus der letzten Iteration als Projektionsziele verwendet (Gl. 29 und Gl. 30), was höhere Präzision liefert.

Intuition. Die Signaturstärke eines Gens misst, wie stark dieses Gen in Richtung der Signatur zeigt – also wie sehr es zur Signatur gehört und wie groß sein Beitrag ist.

Schritt 2: Sortierordnungen bestimmen. Gene werden aufsteigend nach ihrer Signaturstärke sortiert:

$$\langle e^g_{I_{k,o}(i+1)} \mid u^g_{k,o} \rangle \;\geq\; \langle e^g_{I_{k,o}(i)} \mid u^g_{k,o} \rangle \qquad \forall\, i \in [1, m-1]. \tag{1.47}$$

Samples analog:

$$\langle e^s_{J_{k,o}(j+1)} \mid u^s_{k,o} \rangle \;\geq\; \langle e^s_{J_{k,o}(j)} \mid u^s_{k,o} \rangle \qquad \forall\, j \in [1, n-1]. \tag{1.48}$$

Intuition. Nach dieser Sortierung ist das Signal bereits *grob* bi-monoton. Die Regression macht daraus eine *exakt* bi-monotone Darstellung.

Schritt 3: Matrix umsortieren und inneren Loop starten. Die sortierte Startmatrix für den inneren Loop:

$$\tilde{M}_{o,0} \;:=\; M_{k-1}\Big[I_{k,o},\, J_{k,o}\Big]. \tag{1.49}$$

Die Startgewichte als äußeres Produkt der Signature-Focus-Gewichte:

$$\tilde{W}_0^{2D} \;:=\; W_0^{2D}\Big[I_{k,o},\, J_{k,o}\Big], \qquad W_0^{2D}(i,j) \;=\; \langle e_i^g \mid w_l^g\rangle \cdot \langle e_j^s \mid w_l^s\rangle. \tag{1.50}$$

Intuition. Gene und Samples, die stark im Signature Focus vertreten sind, bekommen hohe Gewichte und dominieren die Regression. Elemente außerhalb des Focus ($w \approx 0$) haben kaum Einfluss.

Innerer Loop (Index q)

Jede Iteration q besteht aus fünf Teilen.

Teil 1: Zeilenweise GPAV (Genregression). Für jede Genzeile i wird GPAV auf den Vektor $\tilde{M}_{o,q}(i,\cdot)$ mit Gewichten $\tilde{W}_q^{2D}(i,\cdot)$ angewendet. GPAV löst:

$$\min_{\substack{x_1,\dots,x_n \\ x_1 \le \dots \le x_n}} \sum_{j=1}^{n} \tilde{W}_q^{2D}(i,j) \cdot \Big(x_j - \tilde{M}_{o,q}(i,j)\Big)^2. \tag{1.51}$$

Wie GPAV funktioniert (Beispiel). Sei $\mathbf{a} = (2,\ 1,\ 0{,}5,\ 3,\ 2{,}5)$, alle Gewichte $= 1$.

Start: Jeder Index ist sein eigener Block.

j	Block	x_j	W_j
1	$\{1\}$	2	1
2	$\{2\}$	1	1
3	$\{3\}$	0.5	1
4	$\{4\}$	3	1
5	$\{5\}$	2.5	1

Scan von links nach rechts:

- $j = 2$: $2 > 1$ × – fusioniere $\{1\}$ und $\{2\}$:

  $$x = \frac{1 \cdot 2 + 1 \cdot 1}{2} = 1{,}5, \quad W = 2.$$

  Rückwärts: nichts links von $\{1, 2\}$.

- $j = 3$: $1{,}5 > 0{,}5$ × – fusioniere $\{1, 2\}$ und $\{3\}$:

  $$x = \frac{2 \cdot 1{,}5 + 1 \cdot 0{,}5}{3} = \frac{3{,}5}{3} \approx 1{,}17, \quad W = 3.$$

  Rückwärts: nichts links von $\{1, 2, 3\}$.

- $j = 4$: $1{,}17 \leq 3$ ✓ – weiter.
- $j = 5$: $3 > 2{,}5$ × – fusioniere $\{4\}$ und $\{5\}$:

$$x = \frac{1 \cdot 3 + 1 \cdot 2{,}5}{2} = 2{,}75, \quad W = 2.$$

Rückwärts: $1{,}17 \leq 2{,}75$ ✓.

Ergebnis:

j	Block	x_j	W_j
1	$\{1,2,3\}$	1.17	3
2	$\{1,2,3\}$	1.17	3
3	$\{1,2,3\}$	1.17	3
4	$\{4,5\}$	2.75	2
5	$\{4,5\}$	2.75	2

Blockgewicht. Alle Elemente eines Blocks bekommen das akkumulierte Gewicht $W_B = \sum_{j \in B} w_j$. Das kodiert, wie viele Datenpunkte dieser Block repräsentiert – bei späteren Fusionen hat er entsprechend mehr Einfluss. Das Blockgewicht dient ausschließlich der Fusionsberechnung: nach der Fusion repräsentiert der gesamte Block nach außen hin einen einzigen Wert und ein einziges Gewicht.

Das Ergebnis aller Zeilen wird gesammelt in $\tilde{G}^{q+1} \in \mathbb{R}^{m \times n}$ (Werte) und $W^G_{q+1} \in \mathbb{R}^{m \times n}$ (Blockgewichte).

Teil 2: Spaltenweise GPAV (Sampleregression). Analog zu Teil 1, aber für jede Spalte j. GPAV wird auf $\tilde{M}_{o,q}(\cdot, j)$ mit Gewichten $\tilde{W}^{2D}_q(\cdot, j)$ angewendet und erzwingt Monotonie in Genrichtung:

$$\min_{\substack{x_1,\ldots,x_m \\ x_1 \leq \cdots \leq x_m}} \sum_{i=1}^{m} \tilde{W}^{2D}_q(i,j) \cdot \Big(x_i - \tilde{M}_{o,q}(i,j)\Big)^2. \tag{1.52}$$

Wichtig. Die Gewichte für die Spaltenregression kommen aus $\tilde{W}^{2D}_q$ – also der Matrix vom Beginn der Iteration q, nicht aus W^G_{q+1}. Zeilen- und Spaltenregression arbeiten parallel auf derselben Eingabe $\tilde{M}_{o,q}$.

Das Ergebnis wird gesammelt in $\tilde{S}^{q+1} \in \mathbb{R}^{m \times n}$ (Werte) und $W^S_{q+1} \in \mathbb{R}^{m \times n}$ (Blockgewichte).

Teil 3: Smoothening. Das Smoothening $\mathcal{S}_{|u^q_{k,o}\rangle, |u^s_{k,o}\rangle}(\tilde{M}_{o,q})$ wird berechnet (Gl. 32). Es ist ein adaptiver Gaußscher Glättungsoperator im Raum der Signaturstärken und ist nur relevant für Elemente *außerhalb* des Signature Focus (wo $\tilde{W}^{2D}_{q+1} \approx 0$). Damit werden diese Elemente nicht auf null gesetzt, sondern erhalten einen sinnvollen gemittelten Wert.

Teil 4: Gewichte aktualisieren. Die neuen Gewichte für die nächste Iteration kombinieren symmetrisch Zeilen- und Spaltengewichte:

$$\tilde{W}^{2D}_{q+1} = \frac{n\,\tilde{W}^{2D}_{q} + m\,W^{S}_{q+1}}{2(n+m)} + \frac{m\,\tilde{W}^{2D}_{q} + n\,W^{G}_{q+1}}{2(n+m)}\,. \tag{1.53}$$

Intuition. Die Formel gewichtet die Sampleregression (W^S) stärker mit dem Faktor n und die Genregression (W^G) stärker mit dem Faktor m, weil mehr Samples bedeutet, dass die Sampleregression mehr Datenpunkte zusammenfasst – und umgekehrt. Das Ergebnis ist eine symmetrische Kombination beider Blockstrukturen.

Teil 5: Neue Signalmatrix berechnen.

$$\tilde{M}_{o,q+1} = \frac{n\,\tilde{W}^{2D}_{q} + m\,W^{S}_{q+1}}{2(n+m)}\cdot\tilde{G}^{q+1} + \frac{m\,\tilde{W}^{2D}_{q} + n\,W^{G}_{q+1}}{2(n+m)}\cdot\tilde{S}^{q+1} + \left(1-\tilde{W}^{2D}_{q+1}\right)\cdot\mathcal{S}_{|u^g\rangle,|u^s\rangle}(\tilde{M}_{o,q}). \tag{1.54}$$

Die drei Terme haben folgende Bedeutung:

- **Erster Term:** Beitrag der zeilenweise regressierten Matrix $\tilde{G}^{q+1}$, gewichtet durch die sampleorientierten Gewichte.
- **Zweiter Term:** Beitrag der spaltenweise regressierten Matrix $\tilde{S}^{q+1}$, gewichtet durch die genorientierten Gewichte.
- **Dritter Term:** Für Elemente außerhalb des Signature Focus ($\tilde{W}^{2D}_{q+1} \approx 0$) wird das geglättete Signal verwendet.

Konvergenzcheck. Konvergenz ist erreicht, wenn:

$$\mathrm{std}\left(\tilde{M}_{o,q+1} - \tilde{M}_{o,q}\right) < \frac{1}{1000}\cdot\sigma_{\mathrm{noise}}, \tag{1.55}$$

wobei σ_{noise} das Rauschniveau der Daten ist. Das konvergierte Ergebnis $\tilde{M}_{o,\hat{q}}$ wird an den äußeren Loop zurückgegeben.

1.4 Step 4 – Signature signal E_k and its dissection

Überblick

Nach der bi-monotonen Regression in Step 3 liegt das approximierte Signatursignal im sortierten Raum vor. Step 4 überführt es zurück in die Originalordnung und subtrahiert es von der aktuellen Signalmatrix M_{k-1}, sodass die verbleibende Matrix M_k als Eingabe für die nächste Detektionsiteration $k+1$ dient.

Dissektionsstärken D_k

Die *Dissektionsstärken* $D_k \in \mathbb{R}^{m \times n}$ quantifizieren, wie stark jedes Gen-Sample-Paar (i, j) zur Signatur k beiträgt. Sie sind definiert als die komponentenweisen Quadratwurzeln des äußeren Produkts der Signature-Focus-Gewichte:

$$D_k(i,j) \;:=\; \sqrt{\langle e_i^g \mid w_{\hat{l}}^g \rangle \cdot \langle e_j^s \mid w_{\hat{l}}^s \rangle}. \tag{1.56}$$

Intuition. Das äußere Produkt $|w_{\hat{l}}^g\rangle \otimes |w_{\hat{l}}^s\rangle$ beschreibt die zweidimensionale Stärke der Signatur für jedes Gen-Sample-Paar. Die Quadratwurzel normalisiert diese auf eine lineare Skala, die direkt mit dem Signatursignal multipliziert werden kann.

Die Dissektionsstärken in der finalen Signaturordnung $(I_{k,\hat{o}},\, J_{k,\hat{o}})$ – also der Ordnung aus der letzten äußeren Iteration $\hat{o}$ – werden mit

$$\tilde{D} \;:=\; D_k\Big[I_{k,\hat{o}},\, J_{k,\hat{o}}\Big] \tag{1.57}$$

bezeichnet. Pixel mit $\tilde{D}(i,j) = 0$ liegen vollständig außerhalb des Signature Focus und tragen nicht zum Signatursignal bei.

Signatursignal $\tilde{E}_k$ in Signaturordnung

Das Signatursignal wird im sortierten Raum als *komponentenweises Produkt* der Dissektionsstärken mit dem geglätteten bi-monoton regressierten Signal definiert:

$$\tilde{E}_k \;:=\; \tilde{D} \;\odot\; \mathcal{S}_{|u^g_{k,\hat{o}}\rangle,\, |u^s_{k,\hat{o}}\rangle}\Big(\tilde{M}_{\hat{o},\hat{q}}\Big), \tag{1.58}$$

wobei $\odot$ das komponentenweise (Hadamard-)Produkt bezeichnet, $\tilde{M}_{\hat{o},\hat{q}}$ das konvergierte Ergebnis des inneren Loops aus Step 3 ist und $\mathcal{S}_{|u^g\rangle,|u^s\rangle}$ der adaptive Glättungsoperator (Gl. 32) ist, der auf das konvergierte Signal angewendet wird.

Intuition. Die Multiplikation mit $\tilde{D}$ bewirkt zweierlei: Pixel im Kern des Signature Focus ($\tilde{D} \approx 1$) werden nahezu unverändert übernommen, während Pixel am Rand ($\tilde{D} \ll 1$) oder außerhalb ($\tilde{D} = 0$) des Fokus entsprechend abgeschwächt bzw. vollständig auf null gesetzt werden. Dadurch wird vermieden, dass Signal von benachbarten, überlappenden Signaturen fälschlicherweise der aktuellen Signatur zugerechnet wird.

Signatursignal E_k in Referenzordnung

Das Signatursignal in der ursprünglichen Genotyp-/Sample-Ordnung (Referenzordnung) erhält man durch Zurücksortieren:

$$E_k\Big[I_{k,\hat{o}},\ J_{k,\hat{o}}\Big] \ := \ \tilde{E}_k. \tag{1.59}$$

Das bedeutet: der Eintrag $\tilde{E}_k(i', j')$ im sortierten Raum wird an die Position $(i, j) = (I_{k,\hat{o}}(i'),\ J_{k,\hat{o}}(j'))$ in der Originalmatrix geschrieben.

Dissektion – Subtraktion des Signatursignals

Die Dissektion von Signatur k ist eine einfache Matrixsubtraktion:

$$M_k \ := \ M_{k-1} - E_k \ = \ M_0 - \sum_{l=1}^{k} E_l. \tag{1.60}$$

Intuition. Nach der Subtraktion enthält M_k nur noch den Anteil des Signals, der *nicht* durch Signatur k (oder die zuvor dissektierten Signaturen $1, \ldots, k-1$) erklärt wird. Diese verbleibende Matrix M_k ist die Eingabe für die nächste Detektions- und Dissektionsiteration $k + 1$.

Die kumulative Darstellung $M_0 - \sum_{l=1}^{k} E_l$ macht deutlich, dass SDCM eine additive Zerlegung des Gesamtsignals M_0 in Signaturbeiträge $E_1, E_2, \ldots$ und ein Restterm realisiert:

$$M_0 \ = \ \sum_{l=1}^{\hat{k}} E_l \ + \ M_{\hat{k}}, \tag{1.61}$$

wobei $\hat{k}$ die Gesamtanzahl detektierter Signaturen ist und $M_{\hat{k}}$ das nicht erklärte Restsignal (Rauschen und nicht detektierbare Signaturen) darstellt.

Gesamtstruktur von Step 4 im Überblick

- Berechne Dissektionsstärken in Referenzordnung:

$$D_k(i, j) = \sqrt{\langle e_i^g \mid w_{\hat{l}}^g \rangle \cdot \langle e_j^s \mid w_{\hat{l}}^s \rangle}$$

- Sortiere in Signaturordnung: $\tilde{D} = D_k[I_{k,\hat{o}}, J_{k,\hat{o}}]$
- Berechne Signatursignal in Signaturordnung: $\tilde{E}_k = \tilde{D} \odot \mathcal{S}(\tilde{M}_{\hat{o},\hat{q}})$
- Sortiere zurück in Referenzordnung: $E_k[I_{k,\hat{o}}, J_{k,\hat{o}}] := \tilde{E}_k$
- Subtrahiere: $M_k = M_{k-1} - E_k$

FFT Beispiel Schritt für Schritt

Algorithmus (FFT)

```
def fft(p):
    n = len(p)
    if n == 1:
        return p

    p_e = p[0::2]
    p_o = p[1::2]

    y_e = fft(p_e)
    y_o = fft(p_o)

    y = [0]*n
    w = exp(2*pi*i / n)
    w_i = 1

    for j in range(n//2):
        y[j] = y_e[j] + w_i * y_o[j]
        y[j + n//2] = y_e[j] - w_i * y_o[j]
        w_i *= w

    return y
```

Gegeben sei das Polynom mit Koeffizienten:

$$P = [-1, -1, 1, -5, 0, -4, 2, 3]$$

1. Erste Aufteilung

$$P_e = [-1, 1, 0, 2], \quad P_o = [-1, -5, -4, 3]$$

$$\text{fft}(P) = \text{combine}(\text{fft}(P_e), \text{fft}(P_o))$$

2. Linker Teil: fft(P_e)

$$P_e = [-1, 1, 0, 2]$$

Aufteilung:

$$P_{ee} = [-1, 0], \quad P_{eo} = [1, 2]$$

2.1 fft([−1, 0])

$$[-1] \to [-1], \quad [0] \to [0]$$

$$\text{fft}([-1,0]) = [-1+0, -1-0] = [-1,-1]$$

2.2 fft([1, 2])

$$[1] \to [1], \quad [2] \to [2]$$

$$\text{fft}([1,2]) = [1+2, 1-2] = [3,-1]$$

2.3 Kombination ($n = 4$, $w = i$)

$$y_e = [-1,-1], \quad y_o = [3,-1]$$

$$\begin{aligned} y[0] &= -1+3 = 2 \\ y[2] &= -1-3 = -4 \\ y[1] &= -1+i(-1) = -1-i \\ y[3] &= -1-i(-1) = -1+i \end{aligned}$$

$$\text{fft}(P_e) = [2,\ -1-i,\ -4,\ -1+i]$$

3. Rechter Teil: fft(P_o)

$$P_o = [-1,-5,-4,3]$$

Aufteilung:

$$P_{oe} = [-1,-4], \quad P_{oo} = [-5,3]$$

3.1 fft([−1, −4])

$$[-1] \to [-1], \quad [-4] \to [-4]$$

$$\text{fft}([-1,-4]) = [-1-4,\ -1+4] = [-5,3]$$

3.2 fft([−5, 3])

$$[-5] \to [-5], \quad [3] \to [3]$$

$$\text{fft}([-5,3]) = [-5+3,\ -5-3] = [-2,-8]$$

3.3 Kombination

$$y_e = [-5, 3], \quad y_o = [-2, -8]$$

$$\begin{aligned} y[0] &= -5 - 2 = -7 \\ y[2] &= -5 + 2 = -3 \\ y[1] &= 3 + i(-8) = 3 - 8i \\ y[3] &= 3 - i(-8) = 3 + 8i \end{aligned}$$

$$\text{fft}(P_o) = [-7,\ 3 - 8i,\ -3,\ 3 + 8i]$$

4. Finale Kombination ($n = 8$)

$$Y_e = [2,\ -1 - i,\ -4,\ -1 + i]$$
$$Y_o = [-7,\ 3 - 8i,\ -3,\ 3 + 8i]$$

$$\omega = e^{2\pi i/8}$$

4.1 $j = 0$

$$Y[0] = 2 - 7 = -5$$
$$Y[4] = 2 + 7 = 9$$

4.2 $j = 1$

$$\omega = \frac{1 + i}{\sqrt{2}}$$

$$(1 + i)(3 - 8i) = 11 - 5i$$

$$Y[1] = -1 - i + \frac{11 - 5i}{\sqrt{2}}$$
$$Y[5] = -1 - i - \frac{11 - 5i}{\sqrt{2}}$$

4.3 $j = 2$

$$\omega^2 = i$$

$$Y[2] = -4 - 3i$$
$$Y[6] = -4 + 3i$$

4.4 $j = 3$

$$\omega^3 = \frac{-1+i}{\sqrt{2}}$$

$$(-1+i)(3+8i) = -11-5i$$

$$Y[3] = -1+i+\frac{-11-5i}{\sqrt{2}}$$
$$Y[7] = -1+i-\frac{-11-5i}{\sqrt{2}}$$

5. Ergebnis

$$\boxed{\begin{aligned}[&-5,\ -1-i+\tfrac{11-5i}{\sqrt{2}}\,,\ -4-3i,\ -1+i+\tfrac{-11-5i}{\sqrt{2}}\,,\\ &\quad 9,\ -1-i-\tfrac{11-5i}{\sqrt{2}}\,,\ -4+3i,\ -1+i-\tfrac{-11-5i}{\sqrt{2}}]\end{aligned}}$$